Agent conversationnel et chatbot

Utilisation de Large Language Models pour publier une base de connaissances
Partie 4

Nicolas Debeissat
nicolas.debeissat@mail-formateur.net

Plan du module

Pourquoi faire un agent conversationnel ?

Comment défendre votre projet en entreprise ?

Principes de base des LLMs

Ce qui va faire qu'il va donner des bons résultats, ou non

Entraînement - Fine Tuning

Comment adapter ses réponses

Retrieval Augmented Generation

Répondre à partir de vos données

Intégration dans une application

Créer une API à partir de votre modèle

Evaluation

Entraîner votre IA à faire votre évaluation

Retrieval Augmented Generation

Répondre à partir de vos données

Principe du RAG

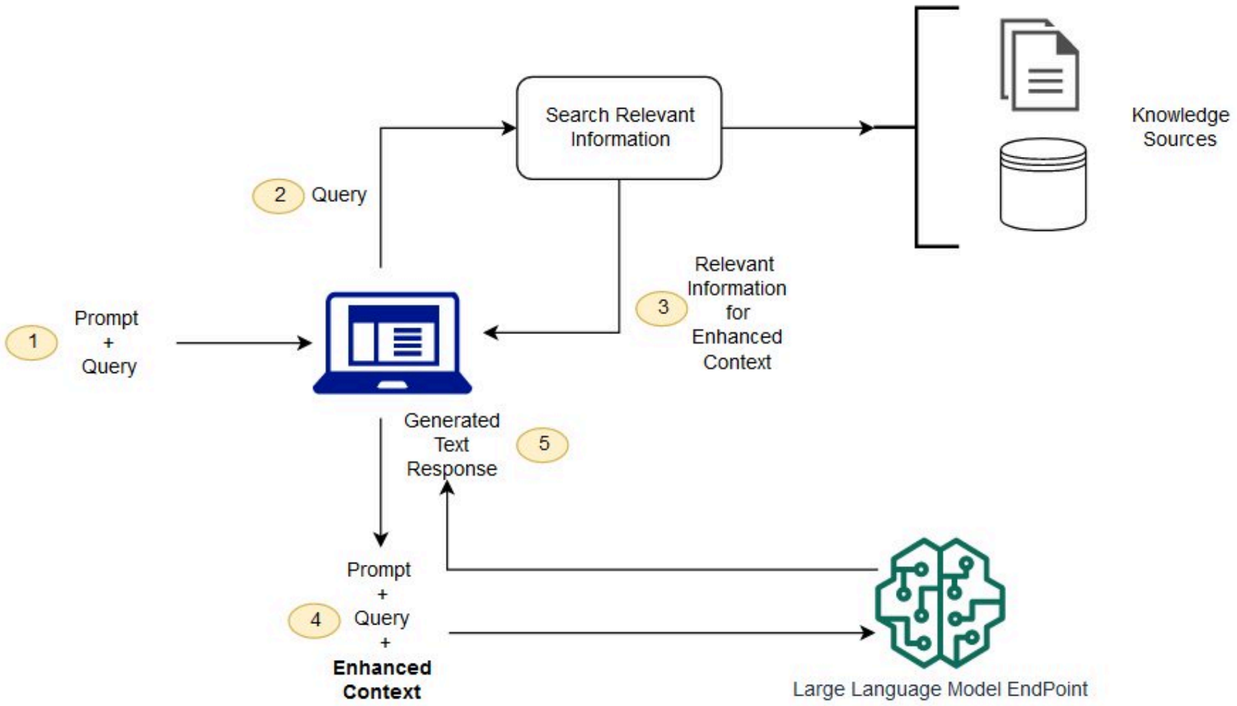

- Recherche dans la base de connaissances des documents les plus appropriés pour répondre à la question.
- Passage dans le prompt pour le LLM du contenu des documents récupérés en lui demandant de répondre à la question en utilisant ces textes.

Few shots learning + structured output

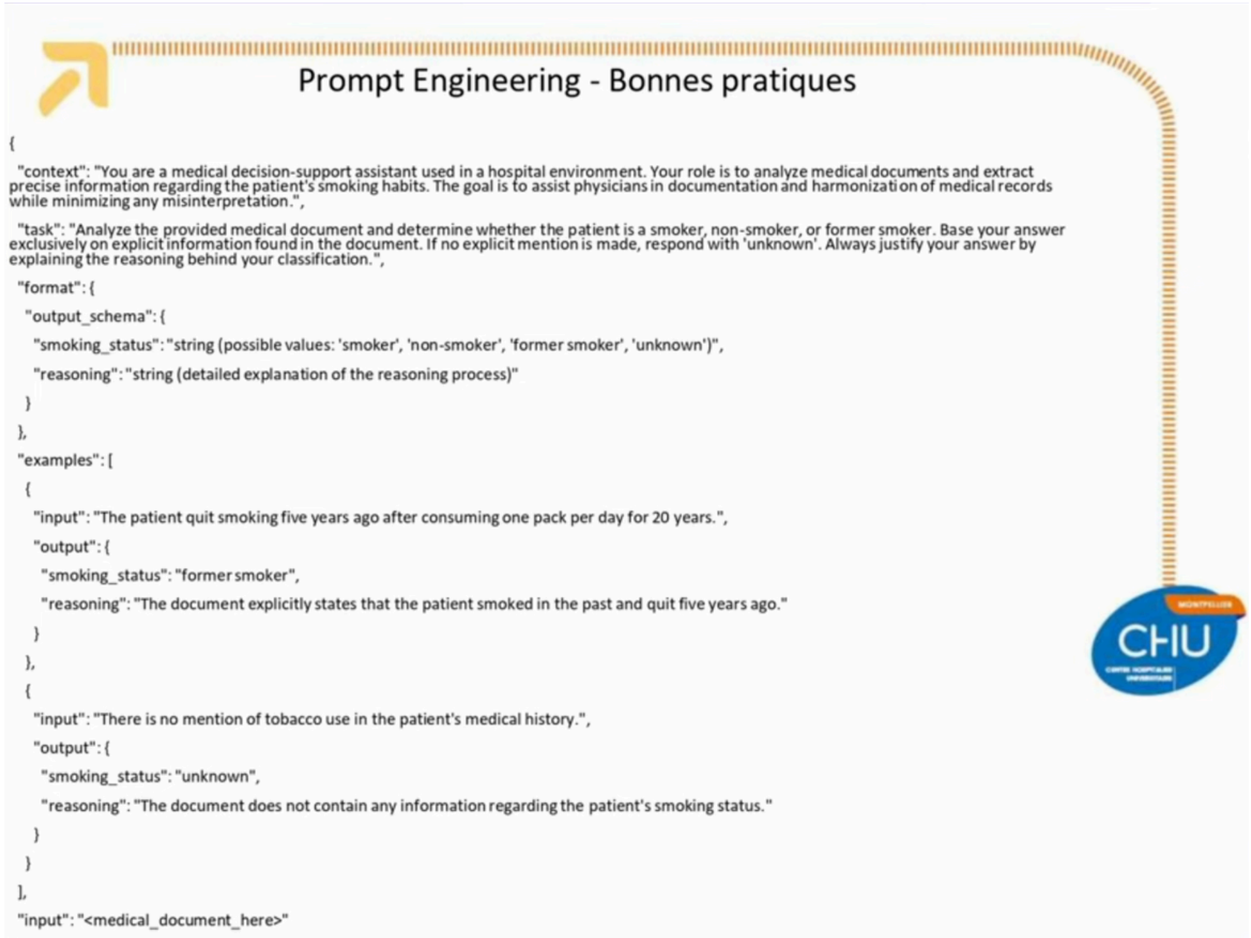

- Prompt système : indique un contexte général, le ton à adopter, le degré de complexité à donner
- instruction : la tâche à réaliser
- Few shots learning : ajout dans le prompt d’exemples de questions-réponses
- structured output : ajout dans le prompt du schéma de la sortie désirée
- le document à analyser
- le raisonnement si le modèle le permet

Après le RAG

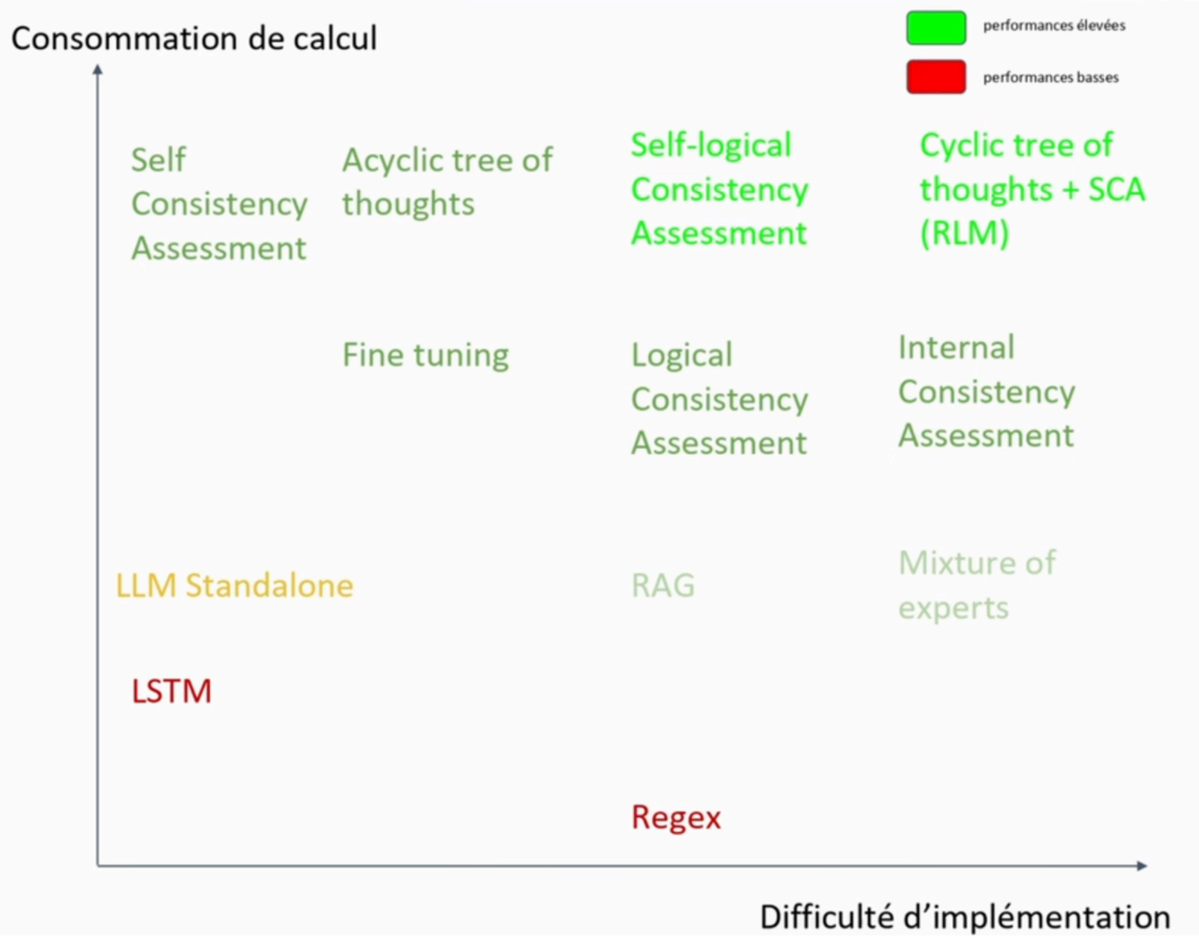

- Vérification du raisonnement suivi par le LLM
- Interrogation en chaîne du modèle pour valider les différentes étapes du raisonnement
- Mesure de l'incertitude en analysant les probabilités générées par le LLM
- etc...

TD4-1 : Déploiement LLM avec ollama

Déployer ollama sur son poste et l'interroger :
https://anakin.ai/blog/how-to-install-ollama-on-windows/
Télécharger l'installeur : https://ollama.com/download/windows
Pour utilisation à distance : créer une variable d'environnement OLLAMA_HOST à 0.0.0.0
Démarrer zephyr : ollama run zephyr
curl http://localhost:11434/api/generate -s -d '{"model": "zephyr", "prompt": "explique-moi le word embedding"}'
puis
curl http://localhost:11434/api/generate -s -d '{"model": "zephyr", "prompt": "explique-moi le word embedding", "stream": false}'

TD4-2 : Déploiement exemple langchain

https://templates.langchain.com/?integration_name=sql-ollama

Installer poetry :
https://python-poetry.org/docs/#installing-with-the-official-installer
poetry new td-langserve
code td-langserve
poetry config virtualenvs.in-project true --local
poetry show -v
modifier : requires-python = ">=3.12,<4.0" dans pyproject.toml
poetry add langchain-cli
source .venv/Scripts/activate
langchain app new my-app
cd ./my-app
langchain app add sql-ollama --branch v0.2

TD4-2 : Déploiement exemple langchain suite

code .
poetry config virtualenvs.in-project true --local
poetry install
source .venv/Scripts/activate
poetry add httpx=0.27.2
dans server.py :
from sql_ollama import chain as sql_ollama_chain
add_routes(app, sql_ollama_chain, path="/sql-ollama")

langchain serve